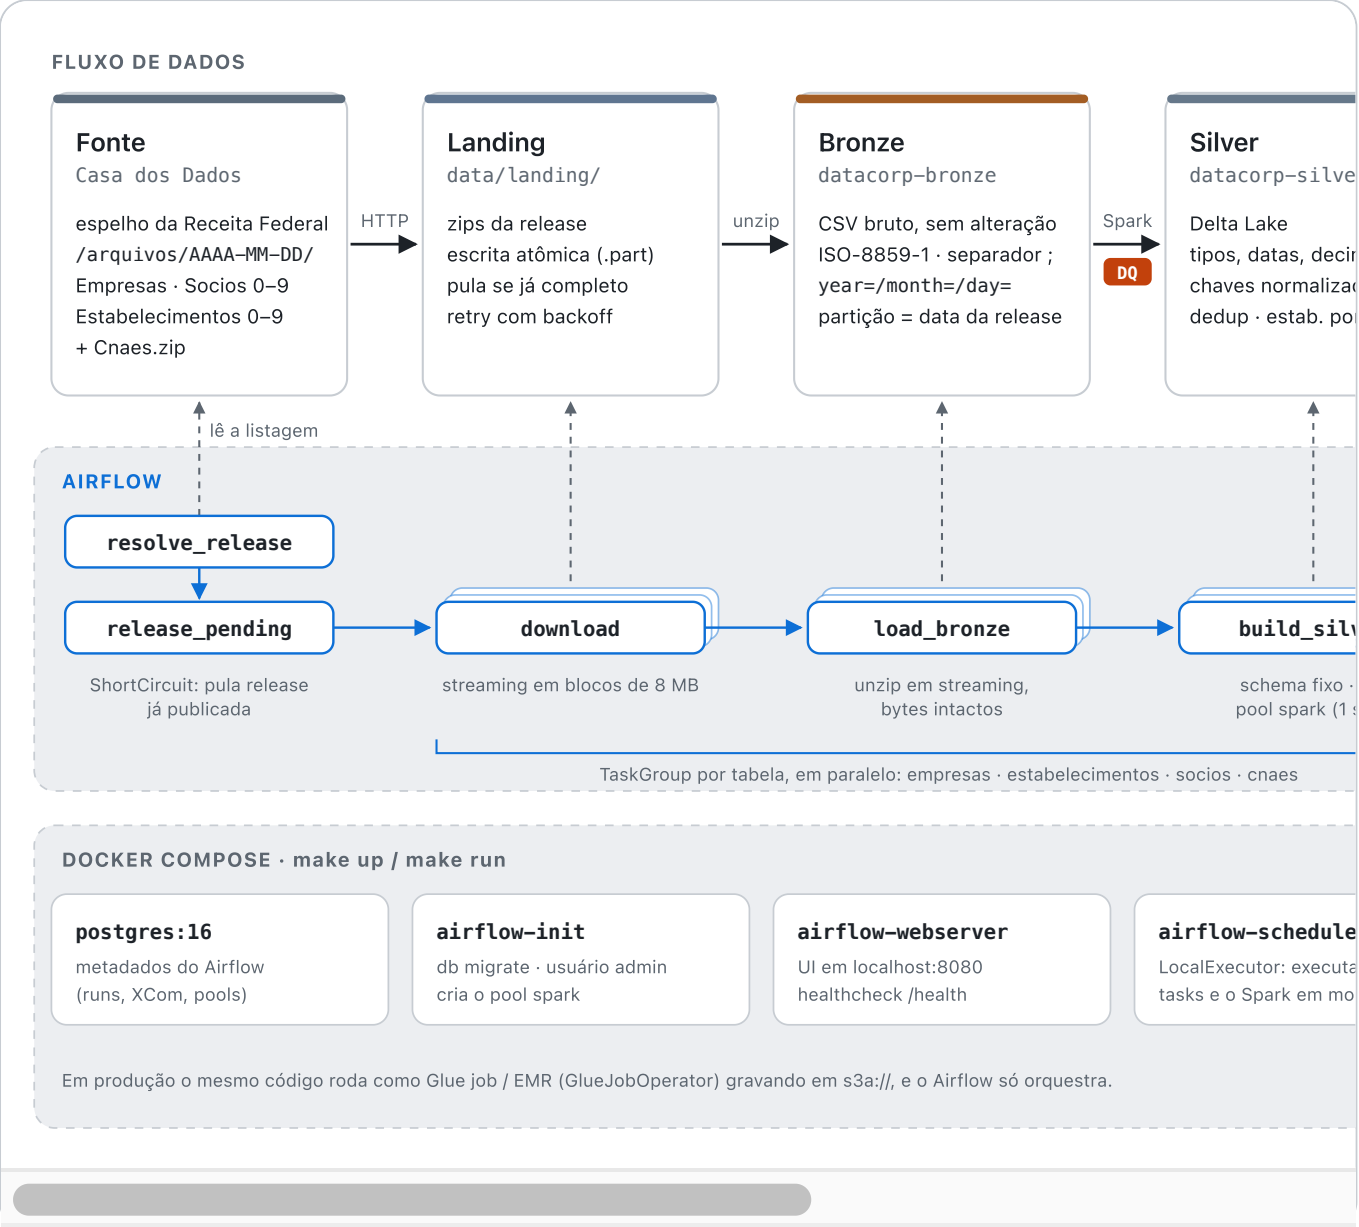
# CNPJ Medallion Pipeline · Arquitetura

Dados Abertos de CNPJ da Receita Federal → Bronze → Silver → Gold, orquestrado pelo Apache Airflow e processado com PySpark + Delta Lake em containers Docker. O lake local simula buckets S3 (`bucket/tabela/particao=valor`).

Bronze · CSV bruto  Silver · Delta tipado  Gold · Delta modelado  Task do Airflow

--- task grava na camada  DQ checagem de qualidade entre camadas




## Camadas

### Bronze

`datacorp-bronze/<tabela>/year=/month=/day=/`

### Silver

`datacorp-silver/<tabela>/_delta_log`

- Cópia fiel dos CSVs da Receita (sem cabeçalho, `;`, ISO-8859-1)
- Partição pela **data da release**, então reprocessar é idempotente
- Permite refazer o Silver sem baixar nada de novo

- empresas · estabelecimentos (por `uf`) · socios · cnaes
- Datas `yyyyMMdd`, decimal BR, códigos → descrições
- CNPJ de 14 dígitos, dedup por chave, colunas de linhagem

### Gold

`datacorp-gold/<tabela>/_delta_log`

- `dim_empresas`, `fact_estabelecimentos` (por `uf`), `rel_empresa_socio`
- `agg_empresas_ativas_cnae_uf`: empresas ativas, % e ranking do CNAE na UF

## Checagens de qualidade (DQ)

| ETAPA | CHECAGEM | SEVERIDADE |
|---|---|---|
| Bronze → Silver | % de linhas malformadas ≤ `DQ_MAX_CORRUPT_RATIO` | `error` |
| Silver | não vazia · chave não nula · chave única | `error` |
| Silver estabelecimentos | `uf` e `situacao_cadastral` dentro do domínio | `warn` |
| Gold | tabelas não vazias · unicidade de dim/fact · uf e CNAE não nulos no agregado | `error` |
| Gold | % de estabelecimentos sem empresa ≤ `DQ_MAX_ORPHAN_RATIO` | `warn` |

## Do local para a AWS

| COMPONENTE | HOJE (LOCAL) | PRODUÇÃO |
|---|---|---|
| Processamento | Spark `local[*]` dentro da task | Glue job / EMR Serverless, mesmo código |

| COMPONENTE | HOJE (LOCAL) | PRODUÇÃO |
|---|---|---|
| Armazenamento | Pastas `data/lake/<bucket>` | S3 com `LAKE_ROOT=s3` → `s3a://<bucket>` |
| Consulta | Spark SQL | Glue Data Catalog + Athena (`sql/athena_gold_tables.sql`) |
| Orquestração | Airflow LocalExecutor no Docker | MWAA / Celery / KubernetesExecutor |
| Download | Uma task por tabela | Dynamic task mapping, uma task por arquivo, direto para S3 |

Abra este arquivo no navegador (`open docs/architecture.html`). Mais detalhes no README.